

# Phân tích khám phá dữ liệu Trivago RecSys Challenge 2019

Ngày 24 tháng 9 năm 2026

## 1 Phạm vi dữ liệu và cách đọc kết quả

Notebook đã quét toàn bộ dữ liệu hành vi: `train.csv` có 15.932.992 event và `test.csv` có 3.782.335 event. Tập metadata có 927.142 dòng; tập submission có 253.573 dòng. Submission là dự đoán mẫu, không phải nhãn thực. Các hình trong báo cáo được lấy trực tiếp từ output đã lưu; báo cáo không chạy lại EDA. Notebook ghi nhận mã băm SHA-256 của bốn tệp nguồn trùng nhau trước và sau lần quét đã lưu.

| Nguồn    | Event/dòng | Session       |
|----------|------------|---------------|
| Train    | 15.932.992 | 910.683       |
| Test     | 3.782.335  | 291.381       |
| Metadata | 927.142    | Không áp dụng |

**Bảng 1:** Quy mô nguồn dữ liệu theo kết quả quét trong notebook.


**Nhận định.** Tập train có hơn bốn lần số event của test. Vì vậy, số lượng tuyệt đối giữa hai tập phải đọc cùng mẫu số; khi so sánh cấu trúc hành vi, cần dùng tỷ lệ hoặc phân phối theo tập.

**Giới hạn diễn giải.** Session được xác định bằng cặp `user_id` và `session_id`. Kiểm tra trùng dòng trong notebook chỉ thực hiện trong từng chunk, chưa loại trừ trùng xuyên ranh giới chunk.

## 2 Hành vi và nhịp thời gian

### 2.1 Phân bố loại hành động

Ở train, `interaction item image` có 11.860.750 event (74,44%), tiếp theo là `clickout item` với 1.586.586 event (9,96%). Test tương ứng có 2.578.455 (68,17%) và 528.779 (13,98%). Cả hai tập có mười loại hành động.




Hình 1: Phân bố action type trong train và test theo output notebook.

**Nhận định.** Tương tác với ảnh chiếm đa số event, còn clickout ít hơn nhiều. Tần suất event không đại diện trực tiếp cho số người dùng hay số phiên: một phiên có thể tạo nhiều event cùng loại. Khi xây mô hình, cần phân biệt hành vi xem xét và clickout mục tiêu.

**Giới hạn diễn giải.** Khác biệt tỷ trọng giữa train và test chỉ là khác biệt quan sát trong hai khoảng dữ liệu, không chứng minh hành vi người dùng đã thay đổi. Phân bố action không đo hiệu quả gợi ý.

## 2.2 Event theo giờ địa phương ước lượng




Hình 2: Số event train theo giờ địa phương và nhóm múi giờ.

**Nhận định.** Các đường cho thấy nhịp hoạt động theo giờ và khác biệt quy mô giữa nhóm thị trường. Đây là gợi ý để kiểm tra tính chu kỳ thời gian hoặc tạo đặc trưng giờ địa phương cho mô hình.

**Giới hạn diễn giải.** Giờ địa phương được suy ra từ múi giờ đại diện của platform; platform là thị trường website, không phải vị trí chính xác của người dùng. Nhóm có quy mô khác nhau và khoảng đầu/cuối quan sát có thể không đủ ngày; chiều cao đường không phải xác suất sử dụng.

## 2.3 Clickout theo giờ địa phương ước lượng



**Hình 3:** Số clickout train theo giờ địa phương và nhóm múi giờ.


**Nhận định.** Clickout cũng có nhịp theo giờ, nhưng số lượng thấp hơn event. Để kết luận một giờ có xu hướng click cao hơn, cần chia số clickout cho một mẫu số phù hợp như số phiên hoặc số cơ hội hiển thị tại cùng giờ và nhóm.

**Giới hạn diễn giải.** Hình là số đếm clickout có **reference**, không phải click-through rate. Quy tắc ánh xạ platform sang múi giờ và thay đổi giờ mùa hè ảnh hưởng vị trí đỉnh.

### 3 Cấu trúc session và chất lượng dữ liệu

#### 3.1 Độ dài session

Train có trung vị 4 event/session, P90 là 41, P99 là 212 và lớn nhất 3.522; test lần lượt là 3, 31, 152 và 2.815. Trung bình train 17,50 lớn hơn nhiều trung vị.




Hình 4: Độ dài session theo số event và thứ hạng quan sát.

**Nhận định.** Phân phối lệch phải rất mạnh: phần lớn session ngắn, nhưng một số session cực dài. Pipeline tuần tự nên xử lý độ dài biến thiên, ví dụ giới hạn lịch sử theo ngưỡng nghiên cứu và báo cáo tỷ lệ session bị cắt. Giá trị P99 quan trọng hơn chỉ riêng trung bình khi ước lượng bộ nhớ.

**Giới hạn diễn giải.** Độ dài session là số event, không phải số clickout, số khách sạn hay thời gian sử dụng. Cực trị cần kiểm tra riêng trước khi gán nhãn bất thường.

### 3.2 Thiếu dữ liệu và kiểm tra hợp lệ

Trên mẫu số event train, `current_filters` thiếu 92,76%; `impressions` và `prices` cùng thiếu 90,04%. Ở test, các tỷ lệ lần lượt là 90,94% và 86,02%; `reference` thiếu trên 261.731 event test (6,92% tổng event test). Notebook không ghi nhận timestamp lỗi chuyển kiểu, timestamp âm hoặc step thiếu/không hợp lệ.



Hình 5: Tỷ lệ thiếu theo cột và tập dữ liệu, mẫu số là event.


**Nhận định.** Thiếu `impressions/prices` ở cấp event chủ yếu phản ánh cấu trúc action: danh sách candidate và giá xuất hiện tại clickout. Không nên điền giá trị giả cho mọi event. Trong test, phần lớn `reference` thiếu tập trung ở clickout cần dự đoán.

**Giới hạn diễn giải.** Tỷ lệ thiếu ở cấp event không mô tả độ đầy đủ của từng clickout; mục sau kiểm tra riêng ở cấp clickout. Kiểm tra duplicate dòng/key của notebook thực hiện trong chunk, nên kết quả 0 không bao phủ trùng xuyên chunk.

## 4 Clickout, nhãn quan sát và candidate

### 4.1 Độ bao phủ của danh sách candidate

Train có 1.586.586 clickout query, tất cả có **reference**, **impressions** đọc được và **prices** căn đúng số phần tử. Trong đó 1.585.837 clickout chọn khách sạn nằm trong **impressions**; 749 chọn ngoài danh sách, chiếm 0,0472%. Test có 528.779 clickout, trong đó 253.573 không có **reference**; trên 275.206 clickout test có **reference** quan sát, 275.059 nằm trong danh sách và 147 nằm ngoài. Notebook không ghi nhận candidate trùng hoặc lệch số phần tử giữa giá và impression tại clickout.




**Hình 6:** Trạng thái nhãn train so với candidate được hiển thị.

**Nhận định.** Danh sách impression bao phủ gần như toàn bộ khách sạn được click trong train, nên bài toán xếp hạng trên tập candidate quan sát là phù hợp với phần lớn clickout. Tuy nhiên 749 trường hợp ngoài danh sách cần quy tắc xử lý rõ khi huấn luyện và đánh giá. Ghép giá với khách sạn phải theo vị trí, không được làm mất token trống trước khi căn hàng.

**Giới hạn diễn giải.** Đây là độ bao phủ candidate set, không phải accuracy của mô hình. **reference** là click được quan sát, không xác nhận đặt phòng. Các **reference** bị ẩn ở test không được suy ra từ tập submission.

### 4.2 Số candidate mỗi query

Trong 2.115.365 clickout query train và test, trung vị, P90, P95, P99 và cực đại đều là 25 candidate duy nhất; 77,69% query có đúng 25 candidate, 22,31% có ít hơn và không có query vượt 25.



Hình 7: Phân phối số candidate duy nhất trong mỗi clickout query.

**Nhận định.** Độ dài danh sách thường bằng 25 nhưng không cố định. Mô hình xếp hạng nên nhận danh sách candidate thực tế và mask phần đệm; giả định mọi query có 25 khách sạn sẽ tạo candidate giả cho hơn một phần năm query.

**Giới hạn diễn giải.** Các con số gộp train và test, mô tả cấu trúc impression quan sát chứ không nói bao nhiêu khách sạn phù hợp với người dùng.

## 5 Độ thưa và mức tập trung

### 5.1 Quan hệ quan sát được

Train có 1.354.909 cặp session–khách sạn đã click duy nhất trên 239.375.720.052 cặp khả dĩ; 1.306.901 cặp user–khách sạn trên 207.799.879.644 cặp khả dĩ. Ở quan hệ clickout query–candidate, có 48.524.284 cặp duy nhất trên 1.915.016.665.485 cặp khả dĩ. Theo công thức  $S = 1 - |E|/(|L| \times |R|)$ , cả ba độ thưa đều rất gần 100% (bảng notebook làm tròn hai chữ số).

**Nhận định.** Ma trận user/item và session/item toàn cục rất thưa; cách đặt bài toán quanh candidate từng query tránh phải chấm điểm toàn bộ kho khách sạn cho mọi truy vấn. Có thể kết hợp ngữ cảnh phiên, vị trí impression, giá và thuộc tính khách sạn khi nghiên cứu mô hình.

**Giới hạn diễn giải.** Một cặp không có click chưa chắc đã được hiển thị, nên không được coi mặc định là phản hồi tiêu cực. Độ thưa toàn cục cũng không phải độ thưa của danh sách 25 candidate tại một clickout.

### 5.2 Tập trung click theo khách sạn

Hệ số Gini là 0,62596 trên 289.506 khách sạn có click, đo bằng 1.354.909 cặp session–khách sạn duy nhất.

**Nhận định.** Click không phân bố đều giữa các khách sạn; các khách sạn phổ biến có thể chi phối tín hiệu học. Khi đánh giá, nên xem kết quả theo mức phổ biến của khách sạn để nhận diện mô hình chỉ ưu tiên nhóm đầu.

**Giới hạn diễn giải.** Gini được tính trên khách sạn đã có click, không gồm toàn bộ catalog. Nó không xác định nguyên nhân của mức tập trung: số lần hiển thị, vị trí, giá, thị trường và chất lượng khách sạn đều có thể liên quan.

## 6 Tỷ lệ được chọn và phân nhóm thiết bị

### 6.1 Tỷ lệ chọn candidate trên train

Trong 1.585.837 clickout train đủ điều kiện, 36.361.011 lượt candidate được hiển thị và 1.585.837 lượt candidate được chọn. Tỷ lệ chọn trên exposure là 4,36%.


**Nhận định.** Chỉ số này là mức nền mô tả dữ liệu: một clickout thường có một lựa chọn trong danh sách nhiều candidate. Nó giúp kiểm tra mẫu số khi phân nhóm, nhưng không thể dùng làm kết quả của thuật toán.

**Giới hạn diễn giải.** Tử số là candidate được chọn, mẫu số là lượt hiển thị; tỷ lệ phụ thuộc độ dài danh sách và chỉ tính các clickout train có nhãn nằm trong impression. Nó không phải accuracy, xác suất đặt phòng hay CTR toàn bộ hệ thống.

### 6.2 Theo thiết bị

| Thiết bị | Clickout query | Lượt candidate | Tỷ lệ chọn |
|----------|----------------|----------------|------------|
| Mobile   | 873.884        | 19.940.951     | 4,38%      |
| Desktop  | 577.293        | 13.312.701     | 4,34%      |
| Tablet   | 134.660        | 3.107.359      | 4,33%      |

**Bảng 2:** Quy mô và tỷ lệ chọn candidate theo thiết bị ở train đủ điều kiện.



**Hình 8:** Số lượt hiển thị và tỷ lệ chọn theo thiết bị; hai trục có đơn vị khác nhau.

**Nhận định.** Mobile đóng góp số clickout và exposure lớn nhất. Tỷ lệ chọn của ba nhóm chỉ cách nhau tối đa 0,05 điểm phần trăm; quy mô và tỷ lệ cần được đọc riêng. Thiết bị có thể hữu ích như ngữ cảnh để phân tầng đánh giá.

**Giới hạn diễn giải.** So sánh thô chưa điều chỉnh số candidate, vị trí, thị trường, thời điểm hay loại khách sạn, nên không chứng minh thiết bị gây ra chênh lệch click.

## 7 Thời điểm clickout trong lịch sử quan sát

### 7.1 Step đầu tiên trong session


Có 826.842/910.683 session train có clickout với step hợp lệ (90,79%); 83.841 session không có clickout (9,21%). Trong nhóm có clickout, step đầu tiên có trung vị 2, P90 là 19 và P99 là 102.

**Nhận định.** Nhiều phiên click sớm, nhưng phần đuôi dài cho thấy vẫn có nhóm cần lịch sử ngữ cảnh đáng kể. Đánh giá mô hình theo độ dài tiền tố trước click có thể chỉ ra mô hình hoạt động khác nhau ở phiên ngắn và dài.

**Giới hạn diễn giải.** First-click step không phải tổng độ dài session: event có thể tiếp diễn sau clickout. Session chưa click trong cửa sổ quan sát không đồng nghĩa không quan tâm khách sạn.

## 7.2 Session đầu tiên có clickout theo user

Trong 730.803 user train, 717.774 có clickout quan sát được (98,22%), còn 13.029 chưa có (1,78%). Trong nhóm có clickout, 692.602 user đã click ở session quan sát thứ nhất, 22.524 ở thứ hai, 2.102 ở thứ ba; số lượng sau đó giảm nhanh.



**Hình 9:** Chỉ số session quan sát đầu tiên có clickout của mỗi user.

**Nhận định.** Phần lớn user có clickout ngay trong session đầu tiên được ghi lại. Do đó, bài toán với ít lịch sử liên phiên có ý nghĩa thực tế trong tập dữ liệu này; ngữ cảnh của chính session hiện tại có thể quan trọng.

**Giới hạn diễn giải.** “Session đầu tiên” là đầu tiên trong cửa sổ dữ liệu, không nhất thiết là lần truy cập đầu tiên trong đời user. Nhóm chưa click bị kiểm duyệt theo thời gian quan sát và không được gán nhãn dislike.

## 8 Metadata khách sạn

### 8.1 Độ phủ và số thuộc tính

Metadata có 927.142 item ID duy nhất, không có ID trùng. Trong 905.291 khách sạn quan sát từ dữ liệu hành vi, 904.436 có dòng metadata và 855 không có, độ phủ 99,91%. Tất cả dòng metadata có property; trung vị 15 property/item, P90 là 46, P95 là 55, P99 là 71 và cực đại 112.



**Hình 10:** Phân phối số property metadata trên mỗi item có metadata.

**Nhận định.** Độ phủ cao cho phép thử đặc trưng nội dung cho hầu hết khách sạn quan sát. Số property thay đổi rộng, nên biểu diễn đặc trưng cần chịu được số tag khác nhau và tránh để item nhiều tag tự động có điểm cao hơn.

**Giới hạn diễn giải.** 855 item không có dòng metadata khác với item có dòng metadata nhưng 0 property. Độ phủ chỉ xét item đã xuất hiện trong dữ liệu hành vi, không phải mọi khách sạn có thể có trong hệ thống.

## 8.2 Số property và lựa chọn quan sát được


Trong bảng item-level của notebook có 853.542 khách sạn, trong đó 798 thiếu metadata. Bảng dưới tách số *clickout tuyệt đối* khỏi *tỷ lệ candidate được chọn trên exposure*.

| Số property    | Exposure đủ điều kiện | Candidate được chọn | Tỷ lệ |
|----------------|-----------------------|---------------------|-------|
| 1–5            | 4.060.018             | 156.176             | 3,85% |
| 6–10           | 1.210.500             | 45.907              | 3,79% |
| 11–20          | 2.757.834             | 108.623             | 3,94% |
| 21–40          | 11.300.503            | 476.300             | 4,21% |
| > 40           | 17.018.201            | 798.188             | 4,69% |
| Thiếu metadata | 13.955                | 643                 | 4,61% |

**Bảng 3:** Tỷ lệ quan sát ở các clickout train đủ điều kiện; mẫu số là candidate exposure trong từng nhóm.

**Nhận định.** Trong các item có metadata, nhóm trên 40 property có tỷ lệ được chọn cao nhất theo phép gộp thô (4,69%), còn nhóm 6–10 thấp nhất (3,79%). Đây là tín hiệu để kiểm tra phân tầng theo mức độ phong phú metadata, không phải bằng chứng rằng thêm property sẽ làm tăng click. Nhóm thiếu metadata có mẫu số rất nhỏ, cần đọc thận trọng.

**Giới hạn diễn giải.** Nhóm property có thể khác nhau về mức phổ biến, số exposure, vị trí, giá và thị trường. Tỷ lệ này chưa điều chỉnh các yếu tố đó; việc so sánh nhân quả hoặc dùng trực tiếp làm điểm gợi ý là không có cơ sở.



**Hình 11:** Số clickout train tuyệt đối theo nhóm property metadata.

**Nhận định.** Cột cao nhất ở nhóm trên 40 property là 798.526 clickout; nhóm 21–40 có 476.526. Chiều cao cột còn phụ thuộc quy mô hiển thị của từng nhóm, nên muốn so sánh khuynh hướng lựa chọn phải xem tỷ lệ và mẫu số ở bảng ngay trên.

**Giới hạn diễn giải.** Hình vẽ số clickout tuyệt đối, không vẽ tỷ lệ. Các tổng clickout trong hình gồm cả một số trường hợp không thuộc mẫu số exposure đủ điều kiện, nên không lấy chiều cao cột chia trực tiếp cho exposure trong bảng.

## 9 Hàm ý phân tích tiếp theo

1. Đơn vị đánh giá phù hợp là clickout query và tập **impressions** tại query đó. Tách dữ liệu theo thời gian và giữ khóa nguồn/dòng để tránh nhầm session hoặc nhân giữa train và test.
2. Dùng **reference** train làm nhân click quan sát; xử lý riêng 749 clickout ngoài candidate. Không coi candidate không được chọn là dislike chắc chắn hay tập submission là nhân.
3. Báo cáo hiệu quả mô hình theo các nhóm có ý nghĩa: độ dài tiền tố session, thiết bị, số candidate, độ phổ biến khách sạn và mức độ phủ metadata. Các bảng EDA ở trên chưa phải đánh giá mô hình.
4. Với giá và metadata, giữ liên kết vị trí giữa **impressions** và **prices**; dùng nhóm thiếu metadata riêng. Nếu thử đặc trưng property, so sánh trên cùng tập query và cùng thước đo xếp hạng.

*Nguồn duy nhất của số liệu và hình: output đã lưu trong `trivago_recsys_eda.ipynb`. Bản mã, notebook và các hình được đóng gói cùng báo cáo để kiểm tra.*