

Phân tích khám phá dữ liệu Trivago RecSys Challenge 2019

25 tháng 9 năm 2026

1 Phạm vi dữ liệu và cách đọc kết quả

Notebook đã quét toàn bộ dữ liệu hành vi: `train.csv` có 15.932.992 event và `test.csv` có 3.782.335 event. Tập metadata có 927.142 dòng; tập submission có 253.573 dòng. Submission là dự đoán mẫu, không phải nhãn thực. Số liệu dựa trên output đã lưu trong notebook 55 cell; mười hình trích trực tiếp, còn hình action và thiết bị được dựng lại từ các bảng output để ghi đúng đơn vị đo. Báo cáo không chạy lại EDA. Notebook ghi nhận mã băm SHA-256 của bốn tệp nguồn trùng nhau trước và sau lần quét đã lưu.

Nguồn	Event/dòng	Session
Train	15.932.992	910.683
Test	3.782.335	291.381
Metadata	927.142	Không áp dụng

Bảng 1: Quy mô nguồn dữ liệu theo kết quả quét trong notebook.


Nhận định. Tập train có hơn bốn lần số event của test. Vì vậy, số lượng tuyệt đối giữa hai tập phải đọc cùng mẫu số; khi so sánh cấu trúc hành vi, cần dùng tỷ lệ hoặc phân phối theo tập.

Giới hạn diễn giải. Session được xác định bằng cặp `user_id` và `session_id`. Kiểm tra trùng dòng trong notebook chỉ thực hiện trong từng chunk, chưa loại trừ trùng xuyên ranh giới chunk.

2 Hành vi và nhịp thời gian

2.1 Phân bố loại hành động

Ở train, `interaction item image` có 11.860.750 event (74,44%), tiếp theo là `clickout item` với 1.586.586 event (9,96%). Test tương ứng có 2.578.455 (68,17%) và 528.779 (13,98%). Cả hai tập có mười loại hành động.




Hình 1: Mười loại hành động quan sát được trong train và test; dựng từ bảng số đếm của notebook.

Nhận định. Tương tác với ảnh chiếm đa số event, còn clickout ít hơn nhiều. Tần suất event không đại diện trực tiếp cho số người dùng hay số phiên: một phiên có thể tạo nhiều event cùng loại. Khi xây mô hình, cần phân biệt hành vi xem xét và clickout mục tiêu.

Giới hạn diễn giải. Khác biệt tỷ trọng giữa train và test chỉ là khác biệt quan sát trong hai khoảng dữ liệu, không chứng minh hành vi người dùng đã thay đổi. Phân bố action không đo hiệu quả gợi ý.

2.2 Event theo giờ địa phương ước lượng




Hình 2: Số event train theo giờ địa phương và nhóm múi giờ.

Nhận định. Các đường cho thấy nhịp hoạt động theo giờ và khác biệt quy mô giữa nhóm thị trường. Đây là gợi ý để kiểm tra tính chu kỳ thời gian hoặc tạo đặc trưng giờ địa phương cho mô hình.

Giới hạn diễn giải. Giờ địa phương được suy ra từ múi giờ đại diện của platform; platform là thị trường website, không phải vị trí chính xác của người dùng. Nhóm có quy mô khác nhau và khoảng đầu/cuối quan sát có thể không đủ ngày; chiều cao đường không phải xác suất sử dụng.

2.3 Clickout theo giờ địa phương ước lượng



Hình 3: Số clickout train theo giờ địa phương và nhóm múi giờ.


Nhận định. Clickout cũng có nhịp theo giờ, nhưng số lượng thấp hơn event. Để kết luận một giờ có xu hướng click cao hơn, cần chia số clickout cho một mẫu số phù hợp như số phiên hoặc số cơ hội hiển thị tại cùng giờ và nhóm.

Giới hạn diễn giải. Hình là số đếm clickout có **reference**, không phải click-through rate. Quy tắc ánh xạ platform sang múi giờ và thay đổi giờ mùa hè ảnh hưởng vị trí đỉnh.

3 Cấu trúc session và chất lượng dữ liệu

3.1 Độ dài session

Train có trung vị 4 event/session, P90 là 41, P99 là 212 và lớn nhất 3.522; test lần lượt là 3, 31, 152 và 2.815. Trung bình train 17,50 lớn hơn nhiều trung vị.




Hình 4: Độ dài session theo số event và thứ hạng quan sát.

Nhận định. Phân phối lệch phải rất mạnh: phần lớn session ngắn, nhưng một số session cực dài. Pipeline tuần tự nên xử lý độ dài biến thiên, ví dụ giới hạn lịch sử theo ngưỡng nghiên cứu và báo cáo tỷ lệ session bị cắt. Giá trị P99 quan trọng hơn chỉ riêng trung bình khi ước lượng bộ nhớ.

Giới hạn diễn giải. Độ dài session là số event, không phải số clickout, số khách sạn hay thời gian sử dụng. Cực trị cần kiểm tra riêng trước khi gán nhãn bất thường.

3.2 Số session trên mỗi user và thời lượng session

Notebook đếm số session duy nhất trên mỗi user riêng cho train và test, theo khóa (file, user_id, session_id). Hình cho thấy phân phối tập trung ở nhóm ít session/user và có phần đuôi dài.



Hình 5: Phân bố số session trên mỗi user theo từng tập; các mức trên 5 session được gom nhóm.

Thời lượng được tính bằng timestamp của event cuối trừ event đầu trong cùng session, đổi sang giờ.

Tập	Nhỏ nhất	P50	P90	P99	Lớn nhất
Train	0	0,031	0,367	1,370	112,334
Test	0	0,024	0,300	1,232	25,398


Bảng 2: Thời lượng session theo giờ, lấy từ bảng kết quả đã lưu trong notebook.

Nhận định. Một user có thể xuất hiện ở nhiều session, nên phân tích liên phiên cần giữ khóa user bên cạnh session. P50 thời lượng khoảng 1,9 phút ở train và 1,4 phút ở test; phần đuôi dài hơn nhiều. Nên phân tầng theo số session đã quan sát khi đánh giá các phương pháp dùng lịch sử user.

Giới hạn diễn giải. Thời lượng là khoảng cách giữa event đầu và cuối, không phải thời gian hoạt động liên tục. Session chỉ có một event có thời lượng 0. Cực đại 112,334 giờ ở train có thể do khoảng không hoạt động hoặc session ID được dùng lại; cần kiểm tra log gốc trước khi diễn giải.

3.3 Thiếu dữ liệu và kiểm tra hợp lệ

Trên mẫu số event train, **current_filters** thiếu 92,76%; **impressions** và **prices** cùng thiếu 90,04%. Ở test, các tỷ lệ lần lượt là 90,94% và 86,02%; **reference** thiếu trên 261.731 event test (6,92% tổng event test). Notebook không ghi nhận timestamp lỗi chuyển kiểu, timestamp âm hoặc step thiếu/không hợp lệ.



Hình 6: Tỷ lệ thiếu theo cột và tập dữ liệu, mẫu số là event.


Nhận định. Thiếu **impressions/prices** ở cấp event chủ yếu phản ánh cấu trúc action: danh sách candidate và giá xuất hiện tại clickout. Không nên điền giá trị giả cho mọi event. Trong test, phần lớn **reference** thiếu tập trung ở clickout cần dự đoán.

Giới hạn diễn giải. Tỷ lệ thiếu ở cấp event không mô tả độ đầy đủ của từng clickout; mục sau kiểm tra riêng ở cấp clickout. Kiểm tra duplicate dòng/key của notebook thực hiện trong chunk, nên kết quả 0 không bao phủ trùng xuyên chunk.

4 Clickout, nhân quan sát và candidate

4.1 Độ bao phủ của danh sách candidate

Train có 1.586.586 clickout query, tất cả có **reference**, **impressions** đọc được và **prices** căn đúng số phần tử. Trong đó 1.585.837 clickout chọn khách sạn nằm trong **impressions**; 749 chọn ngoài danh sách, chiếm 0,0472%. Test có 528.779 clickout, trong đó 253.573 không có **reference**; trên 275.206 clickout test có **reference** quan sát, 275.059 nằm trong danh sách và 147 nằm ngoài. Notebook không ghi nhận candidate trùng hoặc lệch số phần tử giữa giá và impression tại clickout.




Hình 7: Trạng thái nhân train so với candidate được hiển thị.

Nhận định. Danh sách impression bao phủ gần như toàn bộ khách sạn được click trong train, nên bài toán xếp hạng trên tập candidate quan sát là phù hợp với phần lớn clickout. Tuy nhiên 749 trường hợp ngoài danh sách cần quy tắc xử lý rõ khi huấn luyện và đánh giá. Ghép giá với khách sạn phải theo vị trí, không được làm mất token trống trước khi căn hàng.

Giới hạn diễn giải. Đây là độ bao phủ candidate set, không phải accuracy của mô hình. **reference** là click được quan sát, không xác nhận đặt phòng. Các **reference** bị ẩn ở test không được suy ra từ tập submission.

4.2 Số candidate mỗi query

Trong 2.115.365 clickout query train và test, trung vị, P90, P95, P99 và cực đại đều là 25 candidate duy nhất; 77,69% query có đúng 25 candidate, 22,31% có ít hơn và không có query vượt 25.



Hình 8: Phân phối số candidate duy nhất trong mỗi clickout query.

Nhận định. Độ dài danh sách thường bằng 25 nhưng không cố định. Mô hình xếp hạng nên nhận danh sách candidate thực tế và mask phần đệm; giả định mọi query có 25 khách sạn sẽ tạo candidate giả cho hơn một phần năm query.

Giới hạn diễn giải. Các con số gộp train và test, mô tả cấu trúc impression quan sát chứ không nói bao nhiêu khách sạn phù hợp với người dùng.

5 Độ thưa và mức tập trung

5.1 Quan hệ quan sát được

Train có 1.354.909 cặp session–khách sạn đã click duy nhất trên 239.375.720.052 cặp khả dĩ; 1.306.901 cặp user–khách sạn trên 207.799.879.644 cặp khả dĩ. Ở quan hệ clickout query–candidate, có 48.524.284 cặp duy nhất trên 1.915.016.665.485 cặp khả dĩ. Theo công thức $S = 1 - |E|/(|L| \times |R|)$, cả ba độ thưa đều rất gần 100%. Để tránh mất thông tin do làm tròn, mật độ tương ứng là khoảng 5,66; 6,29; và 25,34 cặp quan sát trên một triệu cặp khả dĩ.

Nhận định. Ma trận user/item và session/item toàn cục rất thưa; cách đặt bài toán quanh candidate từng query tránh phải chấm điểm toàn bộ kho khách sạn cho mọi truy vấn. Có thể kết hợp ngữ cảnh phiên, vị trí impression, giá và thuộc tính khách sạn khi nghiên cứu mô hình.

Giới hạn diễn giải. Một cặp không có click chưa chắc đã được hiển thị, nên không được coi mặc định là phản hồi tiêu cực. Độ thưa toàn cục cũng không phải độ thưa của danh sách 25 candidate tại một clickout.

5.2 Tập trung click theo khách sạn

Hệ số Gini là 0,62596 trên 289.506 khách sạn có click, đo bằng 1.354.909 cặp session–khách sạn duy nhất.

Nhận định. Click không phân bố đều giữa các khách sạn; các khách sạn phổ biến có thể chi phối tín hiệu học. Khi đánh giá, nên xem kết quả theo mức phổ biến của khách sạn để nhận diện mô hình chỉ ưu tiên nhóm đầu.

Giới hạn diễn giải. Gini được tính trên khách sạn đã có click, không gồm toàn bộ catalog. Nó không xác định nguyên nhân của mức tập trung: số lần hiển thị, vị trí, giá, thị trường và chất lượng khách sạn đều có thể liên quan.

6 Cấu trúc danh sách candidate theo thiết bị

6.1 Chỉ số trên clickout train đủ điều kiện

Trong 1.585.837 clickout train có nhãn nằm trong impression, có 36.361.011 lượt candidate được hiển thị. Mỗi clickout này có đúng một candidate được chọn, nên tỷ lệ $1.585.837/36.361.011 = 4,36\%$ là nghịch đảo của số candidate trung bình mỗi clickout (22,93).


Nhận định. Tỷ lệ này là phép kiểm tra cấu trúc danh sách và mẫu số, không phản ánh xác suất người dùng thực hiện clickout. Để đánh giá xếp hạng cần xem vị trí của candidate được chọn trong từng query và dùng thước đo theo query.

Giới hạn diễn giải. Chỉ tính các clickout train có nhãn nằm trong impression. Chỉ số không phải CTR toàn bộ hệ thống, accuracy hay xác suất đặt phòng.

6.2 Theo thiết bị

Thiết bị	Clickout query	Lượt candidate	Candidate/query
Mobile	873.884	19.940.951	22,82
Desktop	577.293	13.312.701	23,06
Tablet	134.660	3.107.359	23,08

Bảng 3: Quy mô và số candidate trung bình mỗi clickout theo thiết bị ở train đủ điều kiện.



Hình 9: Số clickout query và độ dài danh sách candidate trung bình theo thiết bị; dựng từ bảng output notebook.

Nhận định. Mobile đóng góp nhiều clickout và lượt hiển thị nhất. Độ dài danh sách trung bình thấp hơn Desktop và Tablet khoảng 0,24–0,26 candidate/query. Thiết bị là một chiều phân tầng hữu ích khi xem quy mô và cấu trúc candidate.

Giới hạn diễn giải. Vì mỗi query trong bảng có đúng một candidate được chọn, nghịch đảo của cột candidate/query chính là tỷ lệ chọn trên exposure. Không được diễn giải chênh lệch đó thành khác biệt về xu hướng click giữa các thiết bị.

7 Thời điểm clickout trong lịch sử quan sát

7.1 Step đầu tiên trong session


Có 826.842/910.683 session train có clickout với step hợp lệ (90,79%); 83.841 session không có clickout (9,21%). Trong nhóm có clickout, step đầu tiên có trung vị 2, P90 là 19 và P99 là 102.

Nhận định. Nhiều phiên click sớm, nhưng phần đuôi dài cho thấy vẫn có nhóm cần lịch sử ngữ cảnh đáng kể. Đánh giá mô hình theo độ dài tiền tố trước click có thể chỉ ra mô hình hoạt động khác nhau ở phiên ngắn và dài.

Giới hạn diễn giải. First-click step không phải tổng độ dài session: event có thể tiếp diễn sau clickout. Session chưa click trong cửa sổ quan sát không đồng nghĩa không quan tâm khách sạn.

7.2 Session đầu tiên có clickout theo user

Trong 730.803 user train, 717.774 có clickout quan sát được (98,22%), còn 13.029 chưa có (1,78%). Trong nhóm có clickout, 692.602 user đã click ở session quan sát thứ nhất, 22.524 ở thứ hai, 2.102 ở thứ ba; số lượng sau đó giảm nhanh.



Hình 10: Chỉ số session quan sát đầu tiên có clickout của mỗi user.

Nhận định. Phần lớn user có clickout ngay trong session đầu tiên được ghi lại. Do đó, bài toán với ít lịch sử liên phiên có ý nghĩa thực tế trong tập dữ liệu này; ngữ cảnh của chính session hiện tại có thể quan trọng.

Giới hạn diễn giải. “Session đầu tiên” là đầu tiên trong cửa sổ dữ liệu, không nhất thiết là lần truy cập đầu tiên trong đời user. Nhóm chưa click bị kiểm duyệt theo thời gian quan sát và không được gán nhãn dislike.

8 Metadata khách sạn

8.1 Độ phủ và số thuộc tính

Metadata có 927.142 item ID duy nhất, không có ID trùng. Mẫu số độ phủ gồm 905.291 khách sạn xuất hiện trong candidate impression của train hoặc test, cộng với khách sạn được click trong train: 904.436 có dòng metadata và 855 không có, độ phủ 99,91%. Tất cả dòng metadata có property; trung vị 15 property/item, P90 là 46, P95 là 55, P99 là 71 và cực đại 112.



Hình 11: Phân phối số property metadata trên mỗi item có metadata.

Nhận định. Độ phủ cao cho phép thử đặc trưng nội dung cho hầu hết khách sạn quan sát. Số property thay đổi rộng, nên biểu diễn đặc trưng cần chịu được số tag khác nhau và tránh để item nhiều tag tự động có điểm cao hơn.

Giới hạn diễn giải. 855 item không có dòng metadata khác với item có dòng metadata nhưng 0 property. Độ phủ chỉ xét item đã xuất hiện trong dữ liệu hành vi, không phải mọi khách sạn có thể có trong hệ thống.

8.2 Số property và lựa chọn quan sát được


Trong bảng item-level *chỉ thuộc train* của notebook có 853.542 khách sạn từ candidate impression hoặc clickout reference, trong đó 798 thiếu metadata. Vì phạm vi này không gồm candidate chỉ thấy ở test, hai số 853.542/798 khác với mẫu số độ phủ 905.291/855 ở trên. Bảng dưới chỉ dùng candidate exposure tại clickout train có nhãn thuộc impression.

Số property	Exposure đủ điều kiện	Candidate được chọn	Tỷ lệ
1–5	4.060.018	156.176	3,85%
6–10	1.210.500	45.907	3,79%
11–20	2.757.834	108.623	3,94%
21–40	11.300.503	476.300	4,21%
> 40	17.018.201	798.188	4,69%
Thiếu metadata	13.955	643	4,61%

Bảng 4: Tỷ lệ quan sát ở các clickout train đủ điều kiện; mẫu số là candidate exposure trong từng nhóm.

Nhận định. Trong các item có metadata, nhóm trên 40 property có tỷ lệ được chọn cao nhất theo phép gộp thô (4,69%), còn nhóm 6–10 thấp nhất (3,79%). Đây là tín hiệu để kiểm tra phân tầng theo mức độ phong phú metadata, không phải bằng chứng rằng thêm property sẽ làm tăng click. Nhóm thiếu metadata có mẫu số rất nhỏ, cần đọc thận trọng.

Giới hạn diễn giải. Nhóm property có thể khác nhau về mức phổ biến, số exposure, vị trí, giá và thị trường. Tỷ lệ này chưa điều chỉnh các yếu tố đó; việc so sánh nhân quả hoặc dùng trực tiếp làm điểm gợi ý là không có cơ sở.



Hình 12: Số clickout train tuyệt đối theo nhóm property metadata.

Nhận định. Cột cao nhất ở nhóm trên 40 property là 798.526 clickout; nhóm 21–40 có 476.526. Chiều cao cột còn phụ thuộc quy mô hiển thị của từng nhóm, nên muốn so sánh khuynh hướng lựa chọn phải xem tỷ lệ và mẫu số ở bảng ngay trên.

Giới hạn diễn giải. Hình vẽ số clickout tuyệt đối, không vẽ tỷ lệ. Các tổng clickout trong hình gồm cả một số trường hợp không thuộc mẫu số exposure đủ điều kiện, nên không lấy chiều cao cột chia trực tiếp cho exposure trong bảng.

9 Hàm ý phân tích tiếp theo

1. Đơn vị đánh giá phù hợp là clickout query và tập **impressions** tại query đó. Tách dữ liệu theo thời gian và giữ khóa nguồn/dòng để tránh nhầm session hoặc nhân giữa train và test.
2. Dùng **reference** train làm nhân click quan sát; xử lý riêng 749 clickout ngoài candidate. Không coi candidate không được chọn là dislike chắc chắn hay tập submission là nhân.
3. Báo cáo hiệu quả mô hình theo các nhóm có ý nghĩa: độ dài tiền tố session, thiết bị, số candidate, độ phổ biến khách sạn và mức độ phủ metadata. Các bảng EDA ở trên chưa phải đánh giá mô hình.
4. Với giá và metadata, giữ liên kết vị trí giữa **impressions** và **prices**; dùng nhóm thiếu metadata riêng. Nếu thử đặc trưng property, so sánh trên cùng tập query và cùng thước đo xếp hạng.

Nguồn số liệu: output đã lưu trong notebook 55 cell `trivago_recsys_eda.ipynb`. Hình action và thiết bị được dựng lại từ bảng output; mười hình còn lại lấy trực tiếp từ notebook.